01 DSA5105 / SLIDES: ERM

Risk / generalization $D = \{(x_i, y_i)\}_{i=1}^n$, $x_i \in \mathbb{R}^d$; samples là rows của X.

$$\hat{R}(f) = \frac{1}{n}\sum_i \ell(f(x_i), y_i),$$

$$R(f) = \mathbb{E}\ell(f(X), Y).$$

ERM: $\min_{f\in\mathcal{H}} \hat{R}(f)$; regularized ERM thêm $\lambda\Omega(f)$. Ba nguồn error: approximation, estimation, optimization. $\mathcal{H}_1 \subseteq \mathcal{H}_2$ làm infimum train objective không tăng; không suy ra test risk giảm.

Data split / CV Train fit parameters; validation/CV chọn hyperparameters; test đánh giá cuối. Mỗi CV fold phải fit preprocessing/PCA trên training fold.

! Low train error không bảo đảm generalization; tránh leakage. Ôn theo nội dung midterm và slide đã có; phạm vi thi chính thức theo thông báo giảng viên.

02 LINEAR / LOSSES / RIDGE

$f_w(x) = w^\top\phi(x)$; $\Phi_{ij} = \phi_j(x_i)$. Linear theo parameters, có thể nonlinear theo input. Với samples là rows:

$J = \frac{1}{2n}\|\Phi w - y\|^2$, $\nabla J = \frac{1}{n}\Phi^\top(\Phi w - y)$.

Normal equation $\Phi^\top\Phi w = \Phi^\top y$. Unique iff full column rank; nếu không, min-norm $w = \Phi^+ y$.

Ridge / feature scaling

$$J_\lambda = \frac{1}{2n}\|\Phi w - y\|^2 + \frac{\lambda}{2}\|w\|^2.$$

$$\hat{w} = (\Phi^\top\Phi + n\lambda I)^{-1}\Phi^\top y.$$

$\lambda > 0$ cho unique ridge khi penalize mọi coefficient. Với $A = \Phi^\top\Phi/n$, eigenvalue μ_j và OLS w_0 khi tồn tại:

$$\langle \hat{w}_\lambda, u_j\rangle = \frac{\mu_j}{\mu_j + \lambda}\langle w_0, u_j\rangle.$$

Directions có eigenvalue nhỏ shrink mạnh hơn. Scaling features đổi effective penalty. Lasso dùng $\lambda\|w\|_1$: nonsmooth, có thể tạo exact zeros.

COND Với unaveraged loss $\|\Phi w - y\|^2/2$ và penalty $\lambda\|w\|^2/2$, inverse chứa λI. Kiểm tra convention và có penalize intercept hay không.

Robust / classification loss Residual $r = \hat{y} - y$: Huber derivative $\psi_\delta(r) = \text{clip}(r, -\delta, \delta)$; constant optimum thỏa $\sum_i \psi_\delta(m - y_i) = 0$. Outlier contribution bị clip thay vì tăng vô hạn như square loss. Margin $m = yf(x)$, $y \in \{\pm 1\}$: $\ell_h(m) = (1-m)_+$; $\ell_{\log}(m) = \log(1 + e^{-m})$. Softmax $p_k = e^{z_k}/\sum_j e^{z_j}$; CE $= -\sum_k y_k \log p_k$; $\nabla_z\ell = p - y$. Binary sigmoid $p = 1/(1+e^{-z})$, $p' = p(1-p)$. Với $y \in \{0,1\}$, binary CE logit gradient $p - y$.

! Cộng cùng constant vào mọi logits không đổi softmax. Square loss nhạy outliers; zero train loss không suy ra zero population risk.

03 GD / SGD / CONVEXITY

$\theta^+ = \theta - \eta\nabla F(\theta)$. SGD dùng minibatch average; uniform sampling cho unbiased estimate. Convex differentiable:

$$F(y) \geq F(x) + \nabla F(x)^\top(y - x).$$

$\nabla^2 F \succeq 0 \Rightarrow$ convex; stationary point là global min. NN nói chung nonconvex.

Smooth-GD proof / quadratic L-smooth: $F(x - \eta g) \leq F(x) - \eta(1 - L\eta/2)\|g\|^2$. Với $\eta = 1/L$, bounded-below F:

$$\min_{t<T}\|g_t\|^2 \leq \frac{2L(F(x_0) - F_{inf})}{T}.$$

Quadratic case từ midterm: SPD Hessian H, $\mu = \lambda_{min}, L = \lambda_{max}$: $e_{t+1} = (I - \eta H)e_t$; convergence mọi start iff $0 < \eta < 2/L$. $\eta^* = 2/(L+\mu)$; contraction factor $(\kappa - 1)/(\kappa + 1)$, $\kappa = L/\mu$.

04 KERNEL / REPRESENTER

$k(x,z) = \langle\phi(x), \phi(z)\rangle$. Valid iff mọi finite Gram K symmetric PSD: $c^\top Kc \geq 0$.

Proof / counterexample Feature map: $c^\top Kc = \|\sum_i c_i\phi(x_i)\|^2$. Invalid: một Gram có negative eigenvalue/quadratic form, hoặc nonsymmetry là đủ. Closure: nonnegative sums, products, $g(x)g(z)k(x,z)$, composition $k(Tx, Tz)$, polynomials với nonnegative coefficients. RBF $e^{-\|x-z\|^2/(2s^2)}$ valid, $s > 0$.

Representer proof $w = w_\parallel + w_\perp$ với $w_\perp \perp \phi_i$: predictions không đổi, norm tăng bởi $\|w_\perp\|^2$. Strict L_2 penalty cho $w_\perp^* = 0$:

$$w^* = \Phi^\top\alpha, \quad f(x) = k_x^\top\alpha.$$

$\dim\text{span}\{\phi_i\} = \text{rank}\,\Phi \leq \min(n, M)$; representer không có nghĩa sparse.

05 KERNEL RIDGE / GEOMETRY

Mean-loss ridge dùng $K = \Phi\Phi^\top$, $K_{ij} = k(x_i, x_j)$:

$$\alpha = (K + n\lambda I)^{-1}y.$$

$$f(x) = \sum_i \alpha_i k(x_i, x).$$

$$\hat{y} = K\alpha, \qquad \|w\|^2 = \alpha^\top K\alpha.$$

Derive: $w^* = \Phi^\top\alpha$ rồi dùng $(\Phi^\top\Phi + cI)^{-1}\Phi^\top = \Phi^\top(K + cI)^{-1}$.

Cost / dimensions $\Phi \in \mathbb{R}^{n\times M}$: feature solve dùng $M \times M$ matrix; kernel solve dùng $n \times n$ matrix. Prediction kernel dùng similarities tới training samples. Chọn formulation theo M, n và cost tính kernel.

Distance in feature space

$$\|\phi(x) - \phi(z)\|^2 = k(x,x) + k(z,z) - 2k(x,z).$$

Kernelization: viết quantity hoàn toàn bằng inner products trước, rồi thay bằng k. Không thay nonlinear operations tùy ý.

Polynomial map $(1 + x^\top z)^2$ có features $1, \sqrt{2}x_j, x_j^2, \sqrt{2}x_j x_\ell$ với $j < \ell$. Cross-term coefficients phải khớp expansion.

! Một vài PSD Gram matrices không chứng minh kernel valid cho mọi finite dataset; một negative Gram đủ để bác bỏ. Nonnegative diagonal một mình chưa đủ.

06 SVM / KKT: SLIDE CONVENTION

Slide dùng $f(x) = w^\top\phi(x)$, *không intercept*. $y_i \in \{\pm 1\}$; geometric margin $y_i f(x_i)/\|w\|$. Normalize min functional margin $= 1$:

$$\min_w \frac{1}{2}\|w\|^2 \quad \text{s.t. } y_i w^\top\phi_i \geq 1.$$

Half-width $1/\|w\|$; full width $2/\|w\|$.

$$\mathcal{L} = \frac{1}{2}\|w\|^2 + \sum_i \alpha_i(1 - y_i w^\top\phi_i).$$

KKT: primal feasible; $\alpha_i \geq 0$; stationarity; complementary slackness:

$$w = \sum_i \alpha_i y_i \phi_i, \quad \alpha_i(1 - y_i w^\top\phi_i) = 0.$$

Substitute w vào Lagrangian, dùng Gram:

$$\max_{\alpha\geq 0} \sum_i \alpha_i - \frac{1}{2}\sum_{ij}\alpha_i\alpha_j y_i y_j k_{ij}.$$

$$\hat{y} = \text{sign}\sum_i \alpha_i y_i k(x_i, x).$$

$\alpha_i > 0 \Rightarrow$ point nằm trên margin; strictly outside margin $\Rightarrow \alpha_i = 0$.

! Active constraint không bắt buộc multiplier dương. Không thêm $\sum_i \alpha_i y_i = 0$ khi objective không có intercept; equality đó chỉ xuất hiện nếu optimize thêm b.

Hinge link $\min_w n^{-1}\sum_i(1 - y_i w^\top\phi_i)_+ + \lambda\|w\|^2/2$. Separable data + sufficiently small penalty cho zero-hinge optimum: rút về min-norm feasible separator. Logistic vẫn dương tại mọi finite margin.

07 DECISION TREES / SPLITS

Leaf optimum: squared loss → mean; absolute loss → median; classification error → mode. Greedy split tối đa hóa

$$\Delta I = I_P - \sum_c \frac{n_c}{n} I_c.$$

Entropy $H = -\sum_k p_k \log_2 p_k$; Gini $G = 1 - \sum_k p_k^2$. Regression dùng child SSE. Deeper tree mở rộng class: optimal train error không tăng; test error không bảo đảm giảm. Pruning/min-leaf/depth kiểm soát variance.

08 BAGGING / RANDOM FOREST

Bagging / random forest Bootstrap samples → fit trees → average/vote. RF thêm random feature subset tại mỗi split.

$$\text{Var}(\bar{T}_B) = \sigma^2\left[\rho_c + \frac{1 - \rho_c}{B}\right].$$

Giả sử equal variances và common pairwise correlation ρ_c; limit $\rho_c\sigma^2$. Tăng B không loại phần correlated. Bagging chủ yếu giảm variance.

Bias–variance Với squared prediction error ở fixed input và independent zero-mean test noise:

$$\mathbb{E}[(Y - \hat{f})^2] = \sigma_\varepsilon^2 + \text{Bias}(\hat{f})^2 + \text{Var}(\hat{f}).$$

Deep tree thường low approximation bias nhưng high variance. Bagging average nhiều unstable learners để giảm variance; RF giảm correlation bằng random feature subsets.

EX $B = 25, \rho_c = .1$: variance factor $.1 + .9/25 = .136$; limit khi $B \to \infty$ là $.1$.

! Random forest không chỉ là khởi tạo khác nhau: bootstrap training rows và random candidate features tại từng split. Averaging không tự xóa bias.

CV / capacity control Với mỗi candidate depth/min-leaf: fit trên $K - 1$ folds, evaluate remaining fold, average scores. Chọn candidate rồi retrain full train; test dùng một lần ở cuối.

09 ADABOOST / TRAIN BOUND

$D_1(i) = 1/n$, weighted error và learner weight:

$$\epsilon_t = \sum_i D_t(i)\mathbf{1}[h_t(x_i) \neq y_i].$$

$$\alpha_t = \tfrac{1}{2}\log\frac{1 - \epsilon_t}{\epsilon_t}.$$

$$D_{t+1}(i) = \frac{D_t(i)e^{-\alpha_t y_i h_t(x_i)}}{Z_t}.$$

$$H(x) = \text{sign}\sum_t \alpha_t h_t(x).$$

$Z_t = (1 - \epsilon_t)e^{-\alpha_t} + \epsilon_t e^{\alpha_t} = 2\sqrt{\epsilon_t(1 - \epsilon_t)}$. Nếu $\epsilon_t = 1/2 - \gamma_t$:

$$\hat{R}_T \leq \prod_t Z_t \leq e^{-2\sum_t \gamma_t^2}.$$

EX $\epsilon = .2 \Rightarrow \alpha = \log 2$, $Z = .8$; mistake/correct relative multiplier $= 4$.

! Weighted error và weighted final vote. Công thức finite weight cần $0 < \epsilon_t < 1$; perfect learner xử lý riêng. Train bound không là test guarantee.

Derive learner weight Exponential loss $L(F) = n^{-1}\sum_i e^{-y_i F(x_i)}$; $F_t = F_{t-1} + \alpha h_t$. Split weighted loss thành correct/mistake:

$$Z(\alpha) = (1 - \epsilon)e^{-\alpha} + \epsilon e^{\alpha}.$$

Đặt $Z'(\alpha) = 0$ cho formula α. Nếu $\epsilon < 1/2$, weight dương; $\epsilon = 1/2$ cho 0; $\epsilon > 1/2$ có thể flip learner.

10 NN / BACKPROPAGATION

$z^\ell = W^\ell h^{\ell-1} + b^\ell$, $h^\ell = \sigma_\ell(z^\ell)$. $\sigma' = \sigma(1 - \sigma)$; $\tanh' = 1 - \tanh^2$; $\text{ReLU}' = \mathbf{1}[z > 0]$ khi $z \neq 0$ (tại 0 chọn subgradient).

Backward recurrence Với $\delta^\ell = \nabla_{z^\ell} L$:

$$\delta^\ell = ((W^{\ell+1})^\top\delta^{\ell+1}) \odot \sigma_\ell'(z^\ell),$$

$$\nabla_{W^\ell} L = \delta^\ell(h^{\ell-1})^\top, \quad \nabla_{b^\ell} L = \delta^\ell.$$

MSE output: $L = (\hat{y} - y)^2/2$, $\delta_{out} = \hat{y} - y$ nếu linear output; thêm output-activation derivative nếu có. Softmax+CE: $\delta_{out} = p - y$. L_2 penalty $\lambda\|W\|_F^2/2$ thêm λW.

EX $z = wx + b, h = \sigma(z), \hat{y} = vh + c$: $\partial_v L = (\hat{y} - y)h, \partial_w L = (\hat{y} - y)v\sigma'(z)x$.

! Forward → loss → backward → update. Shared parameters cộng mọi path. Linear layers chồng nhau vẫn affine; UAT là existence, không là training guarantee.

Matrix backward / shape check $h = Ax$, $A \in \mathbb{R}^{m\times d}$, upstream $\delta \in \mathbb{R}^m$:

$$\nabla_x L = A^\top\delta \in \mathbb{R}^d.$$

$$\nabla_A L = \delta x^\top \in \mathbb{R}^{m\times d}.$$

Input gradient propagates backward; weight gradient là outer product. Chia gradient cho batch size nếu objective là mean loss.

Approximation vs optimization Shallow network $f(x) = \sum_{j=1}^M v_j\sigma(w_j^\top x + b_j)$ học features theo data. Nonpolynomial activation + width đủ lớn cho uniform approximation của continuous functions trên compact domain.

! UAT không hứa finite-width exact fit, GD success hay generalization. Backprop là chain rule + reuse, không là global optimizer.

11 CNN / WEIGHT SHARING

Convolution $\sum_i w_i x_{k-i}$; ML thường dùng cross-correlation $\sum_i w_i x_{k+i}$.

$$d_{out} = \left\lfloor\frac{d + 2p - m}{s}\right\rfloor + 1.$$

Input length d, filter m, padding p, stride s; dilation $= 1$. Valid stride 1: $d - m + 1$.

$$\#params = C_{out}(C_{in}h_k w_k + 1).$$

Một filter nhìn mọi input channels; cùng weights tại mọi vị trí. Locality ≠ sharing. Equivariant: $g(Tx) = Tg(x)$; invariant: $f(Tx) = f(x)$. Convolution hỗ trợ equivariance; pooling/aggregation hỗ trợ approximate invariance.

EX Valid length-3 filter trên length-5 input: output 3, chỉ 3 filter weights; không phải 9 nonzero matrix entries là 9 parameters.

Tied-weight matrix Valid length-3 cross-correlation trên $x \in \mathbb{R}^5$ có matrix

$$A_w = \begin{bmatrix} w_0 & w_1 & w_2 & 0 & 0 \\ 0 & w_0 & w_1 & w_2 & 0 \\ 0 & 0 & w_0 & w_1 & w_2 \end{bmatrix}.$$

Matrix intuition / channels Convolution là sparse structured matrix: locality tạo zeros; sharing tie coefficients. Với nhiều channels, mỗi output channel sum filtered contributions từ *mọi* input channel, rồi thêm một bias và activation.

12 RNN / BPTT

$h_t = g(h_{t-1}, x_t; \theta)$, $L = \sum_t \ell_t(h_t)$; cùng θ qua time. Đặt $\delta_t = \nabla_{h_t} L$:

$$\delta_t = \nabla_{h_t}\ell_t + (J_{h_t} g_{t+1})^\top\delta_{t+1},$$

$$\nabla_\theta L = \sum_t (J_\theta g_t)^\top\delta_t.$$

Linear cell $h_t = Ah_{t-1} + Bx_t$: $\nabla_A L = \sum_t \delta_t h_{t-1}^\top$; $\nabla_B L = \sum_t \delta_t x_t^\top$.

EX $h_t = ah_{t-1} + x_t$, $h_0 = 0$, final MSE: $h_3 = a^2x_1 + ax_2 + x_3$, $dL/da = (h_3 - y)(2ax_1 + x_2)$.

Repeated Jacobian products gây vanishing/exploding gradients; LSTM/GRU dùng gates.

13 PCA: CENTER / EIGENPAIRS

$X_{raw} \in \mathbb{R}^{n\times d}$; $\bar{x} = n^{-1}\sum_i x_i$; $X = X_{raw} - \mathbf{1}\bar{x}^\top$; $S = X^\top X/n$ (centered rows).

$$Su_j = \lambda_j u_j, \quad \lambda_1 \geq \cdots \geq \lambda_d \geq 0.$$

$S = S^\top \geq 0$; chọn orthonormal u_j.

$$\max_{\|u\|=1} u^\top S u \Rightarrow Su = \lambda u.$$

Lagrangian $u^\top Su - \lambda(u^\top u - 1)$; leading eigenvalue cho maximum variance. Với $U_m = [u_1, \ldots, u_m]$:

$$Z = XU_m, \quad \hat{X} = XU_m U_m^\top.$$

Scores $Z \in \mathbb{R}^{n\times m}$ khác reconstruction $\hat{X} \in \mathbb{R}^{n\times d}$. Cộng mean để về raw coordinates.

Variance / optimal reconstruction

$$\frac{1}{n}\|X - \hat{X}\|_F^2 = \sum_{j>m} \lambda_j.$$

$$EVR = \frac{\sum_{j\leq m}\lambda_j}{\sum_j \lambda_j}.$$

Proof cue: $x_i = \sum_j \alpha_{ij} u_j$; approximation trong first m directions dùng coefficients β_{ij}:

$$\|x_i - \hat{x}_i\|^2 = \sum_{j\leq m}(\alpha_{ij} - \beta_{ij})^2 + \sum_{j>m}\alpha_{ij}^2.$$

Chọn $\beta_{ij} = \alpha_{ij} = u_j^\top x_i$; giữ directions có eigenvalues lớn nhất.

EX $S = \left[\begin{smallmatrix} 2.5 & 2 \\ 2 & 2.5 \end{smallmatrix}\right]$: $\lambda = (4.5, .5)$, $u_1 = (1,1)^\top/\sqrt{2}$. Giữ 1 PC: 90% variance; mean squared Euclidean error .5.

! Center bằng train mean; eigenvector sign tùy ý. Nếu repeated eigenvalues, basis trong eigenspace không unique. $1/(n-1)$ đổi eigenvalues, không đổi directions.

14 WHITENING / RECONSTRUCTION

Với positive covariance eigenvalues:

$$X_{white} = XU_m\Lambda_m^{-1/2}.$$

$$X_{white}^\top X_{white}/n = I_m.$$

PCA chỉ rotate sang principal coordinates; whitening rotate *và* rescale từng coordinate bằng standard deviation.

Rank / invertibility Giữ toàn bộ orthonormal basis U: $Z = XU, X = ZU^\top$. Nếu giữ $m < \text{rank}(X)$, reconstruction mất phần discarded eigenspace.

! Không chia cho zero eigenvalues. Unit covariance không suy ra independent hay Gaussian. Sau full whitening mọi unit direction có variance bằng nhau; không còn unique largest-variance axis.

15 FEATURE PCA / AUTOENCODER

Nonlinear features $\phi(x) = (\phi_1(x), \ldots, \phi_M(x))^\top$; $\Phi_{raw} \in \mathbb{R}^{n\times M}$. Center *sau* feature mapping:

$$\bar{\phi} = \frac{1}{n}\sum_i \phi(x_i), \quad \Phi = \Phi_{raw} - \mathbf{1}\bar{\phi}^\top.$$

$$S_\phi = \Phi^\top\Phi/n, \quad Z = \Phi U_m.$$

Chọn top eigenvectors của S_ϕ, không của input covariance nếu đang làm feature-space PCA.

Encoder / decoder PCA encoder $z = U_m^\top x$; decoder $\hat{x} = U_m z$ cho centered input. Nonlinear autoencoder:

$$z = f_\theta(x), \quad \hat{x} = g_\psi(z).$$

$$\min_{\theta,\psi}\frac{1}{n}\sum_i \|x_i - \hat{x}_i\|^2.$$

Latent dimension tạo bottleneck. Train encoder/decoder jointly; reconstruction dùng original dimension. PCA là linear encoder/decoder theo chosen principal subspace.

! Good feature-space reconstruction không tự là good input-space reconstruction; nonlinear feature map có thể không invertible.

16 K-MEANS / HARD ASSIGNMENT

Chọn K trước; $z_i \in \{1, \ldots, K\}$:

$$J(z,\mu) = \sum_i \|x_i - \mu_{z_i}\|^2.$$

Lloyd: initialize centers → assign nearest center → update mean → repeat.

$$z_i \leftarrow \arg\min_k \|x_i - \mu_k\|^2.$$

$$\mu_k \leftarrow \frac{1}{|C_k|}\sum_{i\in C_k} x_i.$$

Mỗi step không tăng J; local optimum phụ thuộc init. Empty cluster phải có rule (vd. reseed). Khởi tạo khác nhau có thể dẫn tới các local optima khác nhau.

EX 1D $x = (0, 2, 8, 10)$, centers $(0, 8)$: assignments $\{0, 2\}, \{8, 10\}$; means $(1, 9)$; $J = 4$.

Assumptions / geometry Squared Euclidean thích clusters gần spherical, scale tương tự. Scaling features đổi assignment. Hard boundary là Voronoi partition.

! Không tự chọn K; không bảo đảm global minimum. Monotone objective không suy ra clustering đúng về ý nghĩa.

17 GAUSSIAN / MIXTURE DENSITY

d-dimensional Gaussian ($\Sigma \succ 0$):

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{e^{-\frac{1}{2}(x-\mu)^\top\Sigma^{-1}(x-\mu)}}{(2\pi)^{d/2}|\Sigma|^{1/2}}.$$

Mahalanobis distance dùng Σ^{-1}; determinant chuẩn hóa density. Diagonal Σ cho independent coordinates *trong Gaussian component*.

Mixture model

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k).$$

$\pi_k \geq 0$, $\sum_k \pi_k = 1$. Latent label z: $P(z = k) = \pi_k$; $p(x \mid z = k) = \mathcal{N}_k(x)$. Log-likelihood $\ell(\theta) = \sum_i \log\sum_k \pi_k \mathcal{N}_k(x_i)$. Một Gaussian MLE: $\hat{\mu} = n^{-1}\sum_i x_i$, $\hat{\Sigma} = n^{-1}\sum_i (x_i - \hat{\mu})(x_i - \hat{\mu})^\top$.

! Density có thể > 1; posterior responsibility luôn trong $[0, 1]$. Mixture Gaussian không nhất thiết Gaussian.

Bayes rule / latent labels $P(A \mid B) = P(B \mid A)P(A)/P(B)$. Posterior = likelihood × prior, rồi normalize qua mọi components. Không bỏ prior khi mixture weights khác nhau.

18 EM: E-STEP / M-STEP

E-step dùng *old* parameters, Bayes rule:

$$r_{ik} = P(z_i = k \mid x_i) = \frac{\pi_k \mathcal{N}_k(x_i)}{\sum_j \pi_j \mathcal{N}_j(x_i)}.$$

$\sum_k r_{ik} = 1$ với mỗi sample. Đặt $N_k = \sum_i r_{ik}$; M-step:

$$\pi_k^+ = N_k/n, \qquad \mu_k^+ = \frac{\sum_i r_{ik} x_i}{N_k},$$

$$\Sigma_k^+ = \frac{1}{N_k}\sum_i r_{ik}(x_i - \mu_k^+)(x_i - \mu_k^+)^\top.$$

Compute mọi responsibility trước, rồi update mọi parameter; covariance dùng *new* mean.

Algorithm loop Initialize π_k, μ_k, Σ_k → compute normalized responsibilities → weighted parameter updates → evaluate log-likelihood → repeat đến tolerance / iteration budget.

! Không bảo đảm global optimum. Covariance phải valid; collapse quanh một point có thể làm likelihood tăng vô hạn. Tránh divide-by-zero khi component effective count quá nhỏ.

Hard vs soft K-means: one-hot assignment theo Euclidean distance. GMM: probability assignment theo prior, covariance shape và density. Equal isotropic covariance + equal priors cho nearest-mean posterior maximizer.

19 MDP / RETURNS / POLICY

MDP $(\mathcal{S}, \mathcal{A}, p, r, \gamma)$; $p(s', r \mid s, a)$ là joint next-state/reward distribution. Markov: next outcome phụ thuộc current state/action, không cần toàn history.

$$G_t = \sum_{k\geq 0}\gamma^k R_{t+k+1}, \quad 0 \leq \gamma < 1.$$

Stochastic policy $\pi(a \mid s)$; deterministic $\mu : \mathcal{S} \to \mathcal{A}$.

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s].$$

$$Q^\pi(s,a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a].$$

$$V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s,a).$$

COND Finite discounted results dưới đây dùng finite states/actions và bounded rewards. Episodic $\gamma = 1$ cần thêm assumptions; không áp dụng contraction một cách máy móc.

20 BELLMAN: EXPECTATION / MAX

Với $r(s,a) = \mathbb{E}[R_{t+1} \mid s, a]$: Policy evaluation:

$$Q^\pi(s,a) = r(s,a) + \gamma\mathbb{E}[V^\pi(S') \mid s, a],$$

$$V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s,a).$$

$P^\pi_{ss'} = \sum_a \pi(a \mid s)P(s' \mid s, a)$, $r^\pi_s = \sum_a \pi(a \mid s) r(s,a)$:

$$V^\pi = r^\pi + \gamma P^\pi V^\pi, \quad V^\pi = (I - \gamma P^\pi)^{-1} r^\pi.$$

Optimality:

$$Q^*(s,a) = r(s,a) + \gamma\mathbb{E}[V^*(S') \mid s, a],$$

$$V^*(s) = \max_a Q^*(s,a).$$

Thay $V^*(s') = \max_{a'} Q^*(s', a')$ cho action-value optimality equation. Greedy policy $\mu^*(s) \in \arg\max_a Q^*(s,a)$.

! Fixed π: average theo π, không max. Q^π lấy action a trước rồi theo π; optimal V, Q unique, optimal policy có thể không unique.

21 VALUE ITERATION / ERROR

Khởi tạo V_0 (thường 0). Mỗi sweep:

$$q_k(s,a) = r(s,a) + \gamma\sum_{s'} P(s' \mid s, a) V_k(s'),$$

$$V_{k+1}(s) = \max_a q_k(s,a).$$

Synchronous: mọi state dùng *old* V_k. Viết action candidates trước khi lấy max; terminal continuation $= 0$ nếu terminal không có future rewards.

Contraction / stopping $\|T^*V - T^*U\|_\infty \leq \gamma\|V - U\|_\infty$; $\|V_k - V^*\|_\infty \leq \gamma^k\|V_0 - V^*\|_\infty$. Nếu $\Delta_k = \|V_{k+1} - V_k\|_\infty$:

$$\|V_{k+1} - V^*\|_\infty \leq \frac{\gamma}{1-\gamma}\Delta_k.$$

EX One-state self-loop, reward $r(a)$: $V^* = \max_a r(a)/(1-\gamma)$. Với $r = 2, \gamma = .5$: $V^* = 4$; $V_0 = 0 \to 2 \to 3 \to 3.5 \to \cdots$.

! Convergence asymptotic không có nghĩa exact optimum trong finite sweeps. Greedy action cần $r + \gamma PV$, không chỉ largest immediate reward.

22 POLICY ITERATION / IMPROVE

1. Chọn deterministic μ. 2. Evaluate $(I - \gamma P^\mu)V^\mu = r^\mu$. 3. $\mu^+(s) \in \arg\max_a[r(s,a) + \gamma\sum_{s'} P(s' \mid s,a)V^\mu(s')]$. 4. Repeat đến policy stable.

Policy improvement: nếu $Q^\pi(s, \pi'(s)) \geq V^\pi(s)$ mọi s, thì $V^{\pi'} \geq V^\pi$.

COND Finite MDP + exact evaluation: finite termination với consistent tie handling (giữ old action nếu đang maximizer). Value iteration khác: backup values, không solve full policy mỗi sweep.

23 MONTE CARLO / TD(0)

Model-based biết p, r; model-free dùng sampled transitions. MC estimates $V^\pi(s)$ bằng average observed returns G_t; cần completed return, không bootstrap.

TD target / error

$$\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t).$$

$$V(s_t) \leftarrow V(s_t) + \alpha\delta_t.$$

TD dùng one-step sample + current value estimate; update trước episode end. Nếu true terminal, bootstrap term 0.

! $V(s') > V(s)$ không đủ để update tăng; phải xét reward *và* discount. TD bootstrap có bias từ estimate, MC thường variance cao hơn.

24 Q-LEARNING / EXPLORATION

Learn Q^* trực tiếp từ transition sample (s, a, r, s'):

$$y = r + \gamma\max_{a'} Q(s', a').$$

$$Q(s,a) \leftarrow Q(s,a) + \alpha[y - Q(s,a)].$$

Target theo Bellman optimality, khác TD evaluation của fixed policy. Current transition chỉ update visited state-action entry.

Behavior vs target ε-greedy: probability ε chọn random action, otherwise chọn $\arg\max_a Q(s,a)$. Exploration tạo samples; target vẫn dùng greedy max ở next state.

! Không thay $\max_{a'} Q(s', a')$ bằng $\max_{a'} Q(s, a')$. True terminal không bootstrap. Function approximation không tự kế thừa convergence của tabular updates.

25 DQN / REPLAY / TARGET NET

Approximate $Q(s, a; \theta)$ bằng neural net. Store (s, a, r, s', d) trong replay buffer; sample random minibatch. $d = 1$ khi true terminal.

$$y = r + \gamma(1-d)\max_{a'} Q(s', a'; \theta^-).$$

$$L(\theta) = \frac{1}{B}\sum_{j=1}^B [y_j - Q(s_j, a_j; \theta)]^2.$$

Giữ target y fixed khi differentiate; optimizer update θ; định kỳ copy $\theta^- \leftarrow \theta$.

Why two mechanisms? Replay giảm sequential correlation và tái sử dụng data; target net làm target thay đổi chậm hơn. Behavior policy tạo data có thể khác greedy target policy.

! Replay không bắt buộc từ current policy. Terminal target $= r$. Neural approximation + bootstrap + off-policy có thể bất ổn; target/replay không chứng minh global convergence.

26 POWER ITERATION / PAGERANK

Với importance truyền theo outgoing links, chọn column-stochastic matrix A: $A_{ij} = 1/d_j^{out}$ nếu $j \to i$. Stationary importance thỏa $Ar = r$.

$$r_{t+1} = Ar_t.$$

Slide Deep RL: eigenvalue lớn nhất là 1, nên có thể bỏ normalization trong mathematical iteration; thực tế vẫn thường normalize để ổn định và giữ probability interpretation.

Teleportation Repair dangling columns bằng probability vector v. Với $0 \leq \alpha < 1$:

$$r_{t+1} = \alpha Ar_t + (1-\alpha)v.$$

$\mathbf{1}^\top v = 1, v > 0$ cho positive Google matrix và unique stationary distribution.

! Nếu dùng row-stochastic transition matrix và column vector, cần transpose. Undamped iteration không luôn converge chỉ vì eigenvalue 1 tồn tại.