01 DSA5105 / SLIDES: ERM

Risk / generalization $D=\{(x_i,y_i)\}_{i=1}^n$, $x_i\in\mathbb{R}^d$; samples là rows của X.

$$\hat{R}(f)=\frac{1}{n}\sum_i \ell(f(x_i),y_i),$$

$$R(f)=\mathbb{E}\ell(f(X),Y).$$

ERM: $\min_{f\in\mathcal{H}}\hat{R}(f)$; regularized ERM thêm $\lambda\Omega(f)$. Ba nguồn error: approximation, estimation, optimization. $\mathcal{H}_1\subseteq\mathcal{H}_2$ làm infimum train objective không tăng; không suy ra test risk giảm.

Data split / CV Train fit parameters; validation/CV chọn hyperparameters; test đánh giá cuối. Mỗi CV fold phải fit preprocessing/PCA trên training fold.

! Low train error không bảo đảm generalization; tránh leakage. Ôn theo nội dung midterm và slide đã có; phạm vi thi chính thức theo thông báo giảng viên.

02 LINEAR / LOSSES / RIDGE

$f_w(x)=w^\top\phi(x)$; $\Phi_{ij}=\phi_j(x_i)$. Linear theo parameters, có thể nonlinear theo input. Với samples là rows:

$J=\frac{1}{2n}\|\Phi w-y\|^2,\quad \nabla J=\frac{1}{n}\Phi^\top(\Phi w-y).$

Normal equation $\Phi^\top\Phi w=\Phi^\top y$. Unique iff full column rank; nếu không, min-norm $w=\Phi^+y$.

Ridge / feature scaling

$J_\lambda=\frac{1}{2n}\|\Phi w-y\|^2+\frac{\lambda}{2}\|w\|^2$.

$\hat{w}=(\Phi^\top\Phi+n\lambda I)^{-1}\Phi^\top y$. $\lambda>0$ cho unique ridge khi penalize mọi coefficient. Với $A=\Phi^\top\Phi/n$, eigenvalue μ_j và OLS w_0 khi tồn tại:

$$\langle\hat{w}_\lambda,u_j\rangle=\frac{\mu_j}{\mu_j+\lambda}\langle w_0,u_j\rangle.$$

Directions có eigenvalue nhỏ shrink mạnh hơn. Scaling features đổi effective penalty. Lasso dùng $\lambda\|w\|_1$: nonsmooth, có thể tạo exact zeros.

COND Với unaveraged loss $\|\Phi w-y\|^2/2$ và penalty $\lambda\|w\|^2/2$, inverse chứa λI. Kiểm tra convention và có penalize intercept hay không.

Robust / classification loss Residual $r=\hat{y}-y$: Huber derivative $\psi_\delta(r)=\text{clip}(r,-\delta,\delta)$; constant optimum thỏa $\sum_i\psi_\delta(m-y_i)=0$. Outlier contribution bị clip thay vì tăng vô hạn như square loss. Margin $m=yf(x)$, $y\in\{\pm1\}$: $\ell_h(m)=(1-m)_+$; $\ell_{\log}(m)=\log(1+e^{-m})$. Softmax $p_k=e^{z_k}/\sum_j e^{z_j}$; CE $=-\sum_k y_k\log p_k$; $\nabla_z\ell=p-y$. Binary sigmoid $p=1/(1+e^{-z})$, $p'=p(1-p)$. Với $y\in\{0,1\}$, binary CE logit gradient $p-y$.

! Cộng cùng constant vào mọi logits không đổi softmax. Square loss nhạy outliers; zero train loss không suy ra zero population risk.

03 GD / SGD / CONVEXITY

$\theta^+=\theta-\eta\nabla F(\theta)$. SGD dùng minibatch average; uniform sampling cho unbiased estimate. Convex differentiable: $F(y)\ge F(x)+\nabla F(x)^\top(y-x)$. $\nabla^2F\succeq0\Rightarrow$ convex; stationary point là global min. NN nói chung nonconvex.

Smooth-GD proof / quadratic L-smooth: $F(x-\eta g)\le F(x)-\eta(1-L\eta/2)\|g\|^2$. Với $\eta=1/L$, bounded-below F:

$$\min_{t<T}\|g_t\|^2\le\frac{2L(F(x_0)-F_{inf})}{T}.$$

Quadratic case từ midterm: SPD Hessian H, $\mu=\lambda_{min}$, $L=\lambda_{max}$: $e_{t+1}=(I-\eta H)e_t$; convergence mọi start iff $0<\eta<2/L$. $\eta^*=2/(L+\mu)$; contraction factor $(\kappa-1)/(\kappa+1)$, $\kappa=L/\mu$.

04 KERNEL / REPRESENTER

$k(x,z)=\langle\phi(x),\phi(z)\rangle$. Valid iff mọi finite Gram K symmetric PSD: $c^\top Kc\ge0$.

Proof / counterexample Feature map: $c^\top Kc=\|\sum_i c_i\phi(x_i)\|^2$. Invalid: một Gram có negative eigenvalue/quadratic form, hoặc nonsymmetry là đủ. Closure: nonnegative sums, products, $g(x)g(z)k(x,z)$, composition $k(Tx,Tz)$, polynomials với nonnegative coefficients. RBF $e^{-\|x-z\|^2/(2s^2)}$ valid, $s>0$.

Representer proof $w=w_\parallel+w_\perp$ với $w_\perp\perp\phi_i$: predictions không đổi, norm tăng bởi $\|w_\perp\|^2$. Strict L_2 penalty cho $w_\perp^*=0$: $w^*=\Phi^\top\alpha$, $f(x)=k_x^\top\alpha$. $\dim\text{span}\{\phi_i\}=\text{rank}\,\Phi\le\min(n,M)$; representer không có nghĩa sparse.

05 KERNEL RIDGE / GEOMETRY

Mean-loss ridge dùng $K=\Phi\Phi^\top$, $K_{ij}=k(x_i,x_j)$: $\alpha=(K+n\lambda I)^{-1}y$. $f(x)=\sum_i\alpha_ik(x_i,x)$.

$\hat{y}=K\alpha$, $\|w\|^2=\alpha^\top K\alpha$. Derive: $w^*=\Phi^\top\alpha$ rồi dùng $(\Phi^\top\Phi+cI)^{-1}\Phi^\top=\Phi^\top(K+cI)^{-1}$.

Cost / dimensions $\Phi\in\mathbb{R}^{n\times M}$: feature solve dùng $M\times M$ matrix; kernel solve dùng $n\times n$ matrix. Prediction kernel dùng similarities tới training samples. Chọn formulation theo M, n và cost tính kernel.

Distance in feature space

$$\|\phi(x)-\phi(z)\|^2=k(x,x)+k(z,z)-2k(x,z).$$

Kernelization: viết quantity hoàn toàn bằng inner products trước, rồi thay bằng k. Không thay nonlinear operations tùy ý.

Polynomial map $(1+x^\top z)^2$ có features $1,\sqrt{2}x_j,x_j^2,\sqrt{2}x_jx_\ell$ với $j<\ell$. Cross-term coefficients phải khớp expansion.

! Một vài PSD Gram matrices không chứng minh kernel valid cho mọi finite dataset; một negative Gram đủ để bác bỏ. Nonnegative diagonal một mình chưa đủ.

06 SVM / KKT: SLIDE CONVENTION

Slide dùng $f(x)=w^\top\phi(x)$, *không intercept*. $y_i\in\{\pm1\}$; geometric margin $y_if(x_i)/\|w\|$. Normalize min functional margin $=1$:

$$\min_w\frac{1}{2}\|w\|^2\quad\text{s.t. } y_iw^\top\phi_i\ge1.$$

Half-width $1/\|w\|$; full width $2/\|w\|$. $\mathcal{L}=\frac{1}{2}\|w\|^2+\sum_i\alpha_i(1-y_iw^\top\phi_i)$. KKT: primal feasible; $\alpha_i\ge0$; stationarity; complementary slackness: $w=\sum_i\alpha_iy_i\phi_i$, $\alpha_i(1-y_iw^\top\phi_i)=0$. Substitute w vào Lagrangian, dùng Gram:

$$\max_{\alpha\ge0}\sum_i\alpha_i-\frac{1}{2}\sum_{ij}\alpha_i\alpha_jy_iy_jk_{ij}.$$

$\hat{y}=\text{sign}\sum_i\alpha_iy_ik(x_i,x)$. $\alpha_i>0\Rightarrow$ point nằm trên margin; strictly outside margin $\Rightarrow\alpha_i=0$.

! Active constraint không bắt buộc multiplier dương. Không thêm $\sum_i\alpha_iy_i=0$ khi objective không có intercept; equality đó chỉ xuất hiện nếu optimize thêm b.

Hinge link

$\min_w n^{-1}\sum_i(1-y_iw^\top\phi_i)_+ +\lambda\|w\|^2/2$. Separable data + sufficiently small penalty cho zero-hinge optimum: rút về min-norm feasible separator. Logistic vẫn dương tại mọi finite margin.

07 DECISION TREES / SPLITS

Leaf optimum: squared loss → mean; absolute loss → median; classification error → mode. Greedy split tối đa hóa $\Delta I=I_P-\sum_c\frac{n_c}{n}I_c$. Entropy $H=-\sum_k p_k\log_2p_k$; Gini $G=1-\sum_kp_k^2$. Regression dùng child SSE. Deeper tree mở rộng class: optimal train error không tăng; test error không bảo đảm giảm. Pruning/min-leaf/depth kiểm soát variance.

08 BAGGING / RANDOM FOREST

Bagging / random forest Bootstrap samples → fit trees → average/vote. RF thêm random feature subset tại mỗi split. $\text{Var}(\bar{T}_B)=\sigma^2\left[\rho_c+\frac{1-\rho_c}{B}\right]$. Giả sử equal variances và common pairwise correlation ρ_c; limit $\rho_c\sigma^2$. Tăng B không loại phần correlated. Bagging chủ yếu giảm variance.

Bias–variance Với squared prediction error ở fixed input và independent zero-mean test noise:

$$\mathbb{E}[(Y-\hat{f})^2]=\sigma_\epsilon^2+\text{Bias}(\hat{f})^2+\text{Var}(\hat{f}).$$

Deep tree thường low approximation bias nhưng high variance. Bagging average nhiều unstable learners để giảm variance; RF giảm correlation bằng random feature subsets.

EX $B=25$, $\rho_c=.1$: variance factor $.1+.9/25=.136$; limit khi $B\to\infty$ là $.1$.

! Random forest không chỉ là khởi tạo khác nhau: bootstrap training rows và random candidate features tại từng split. Averaging không tự xóa bias.

CV / capacity control Với mỗi candidate depth/min-leaf: fit trên $K-1$ folds, evaluate remaining fold, average scores. Chọn candidate rồi retrain full train; test dùng một lần ở cuối.

09 ADABOOST / TRAIN BOUND

$D_1(i)=1/n$, weighted error và learner weight: $\epsilon_t=\sum_iD_t(i)\mathbf{1}[h_t(x_i)\ne y_i]$. $\alpha_t=\frac{1}{2}\log\frac{1-\epsilon_t}{\epsilon_t}$.

$$D_{t+1}(i)=\frac{D_t(i)e^{-\alpha_ty_ih_t(x_i)}}{Z_t}.$$

$H(x)=\text{sign}\sum_t\alpha_th_t(x)$.

$Z_t=(1-\epsilon_t)e^{-\alpha_t}+\epsilon_te^{\alpha_t}=2\sqrt{\epsilon_t(1-\epsilon_t)}$. Nếu $\epsilon_t=1/2-\gamma_t$: $\hat{R}_T\le\prod_tZ_t\le e^{-2\sum_t\gamma_t^2}$.

EX $\epsilon=.2\Rightarrow\alpha=\log2$, $Z=.8$; mistake/correct relative multiplier $=4$.

! Weighted error và weighted final vote. Công thức finite weight cần $0<\epsilon_t<1$; perfect learner xử lý riêng. Train bound không là test guarantee.

Derive learner weight Exponential loss $L(F)=n^{-1}\sum_ie^{-y_iF(x_i)}$; $F_t=F_{t-1}+\alpha h_t$. Split weighted loss thành correct/mistake: $Z(\alpha)=(1-\epsilon)e^{-\alpha}+\epsilon e^{\alpha}$. Đặt $Z'(\alpha)=0$ cho formula α. Nếu $\epsilon<1/2$, weight dương; $\epsilon=1/2$ cho 0; $\epsilon>1/2$ có thể flip learner.

10 NN / BACKPROPAGATION

$z^\ell=W^\ell h^{\ell-1}+b^\ell$, $h^\ell=\sigma_\ell(z^\ell)$. $\sigma'=\sigma(1-\sigma)$; $\tanh'=1-\tanh^2$; ReLU$'=\mathbf{1}[z>0]$ khi $z\ne0$ (tại 0 chọn subgradient).

Backward recurrence Với $\delta^\ell=\nabla_{z^\ell}L$:

$$\delta^\ell=((W^{\ell+1})^\top\delta^{\ell+1})\odot\sigma'_\ell(z^\ell),$$

$$\nabla_{W^\ell}L=\delta^\ell(h^{\ell-1})^\top,\quad\nabla_{b^\ell}L=\delta^\ell.$$

MSE output: $L=(\hat{y}-y)^2/2$, $\delta_{out}=\hat{y}-y$ nếu linear output; thêm output-activation derivative nếu có. Softmax+CE: $\delta_{out}=p-y$. L_2 penalty $\lambda\|W\|_F^2/2$ thêm λW.

EX $z=wx+b$, $h=\sigma(z)$, $\hat{y}=vh+c$: $\partial_vL=(\hat{y}-y)h$, $\partial_wL=(\hat{y}-y)v\sigma'(z)x$.

! Forward → loss → backward → update. Shared parameters cộng mọi path. Linear layers chồng nhau vẫn affine; UAT là existence, không là training guarantee.

Matrix backward / shape check $h=Ax$, $A\in\mathbb{R}^{m\times d}$, upstream $\delta\in\mathbb{R}^m$: $\nabla_xL=A^\top\delta\in\mathbb{R}^d$. $\nabla_AL=\delta x^\top\in\mathbb{R}^{m\times d}$. Input gradient propagates backward; weight gradient là outer product. Chia gradient cho batch size nếu objective là mean loss.

Approximation vs optimization Shallow network $f(x)=\sum_{j=1}^Mv_j\sigma(w_j^\top x+b_j)$ học features theo data. Nonpolynomial activation + width đủ lớn cho uniform approximation của continuous functions trên compact domain.

! UAT không hứa finite-width exact fit, GD success hay generalization. Backprop là chain rule + reuse, không là global optimizer.

11 CNN / WEIGHT SHARING

Convolution $\sum_iw_ix_{k-i}$; ML thường dùng cross-correlation $\sum_iw_ix_{k+i}$. $d_{out}=\left\lfloor\frac{d+2p-m}{s}\right\rfloor+1$. Input length d, filter m, padding p, stride s; dilation $=1$. Valid stride 1: $d-m+1$. $\#params=C_{out}(C_{in}h_kw_k+1)$. Một filter nhìn mọi input channels; cùng weights tại mọi vị trí. Locality ≠ sharing. Equivariant: $g(Tx)=Tg(x)$; invariant: $f(Tx)=f(x)$. Convolution hỗ trợ equivariance; pooling/aggregation hỗ trợ approximate invariance.

EX Valid length-3 filter trên length-5 input: output 3, chỉ 3 filter weights; không phải 9 nonzero matrix entries là 9 parameters.

Tied-weight matrix Valid length-3 cross-correlation trên $x\in\mathbb{R}^5$ có matrix

$$A_w=\begin{bmatrix}w_0&w_1&w_2&0&0\\0&w_0&w_1&w_2&0\\0&0&w_0&w_1&w_2\end{bmatrix}.$$

Matrix intuition / channels Convolution là sparse structured matrix: locality tạo zeros; sharing tie coefficients. Với nhiều channels, mỗi output channel sum filtered contributions từ *mọi* input channel, rồi thêm một bias và activation.

12 RNN / BPTT

$h_t=g(h_{t-1},x_t;\theta)$, $L=\sum_t\ell_t(h_t)$; cùng θ qua time. Đặt $\delta_t=\nabla_{h_t}L$:

$$\delta_t=\nabla_{h_t}\ell_t+(J_{h_t}g_{t+1})^\top\delta_{t+1},$$

$\nabla_\theta L=\sum_t(J_\theta g_t)^\top\delta_t$. Linear cell $h_t=Ah_{t-1}+Bx_t$: $\nabla_AL=\sum_t\delta_th_{t-1}^\top$; $\nabla_BL=\sum_t\delta_tx_t^\top$.

EX $h_t=ah_{t-1}+x_t$, $h_0=0$, final MSE: $h_3=a^2x_1+ax_2+x_3$, $dL/da=(h_3-y)(2ax_1+x_2)$.

Repeated Jacobian products gây vanishing/exploding gradients; LSTM/GRU dùng gates.

13 PCA: CENTER / EIGENPAIRS

Raw columns $x_i\in\mathbb{R}^d$; $\bar{x}=n^{-1}\sum_ix_i$, $\tilde{x}_i=x_i-\bar{x}$. $X\in\mathbb{R}^{n\times d}$ có rows $\tilde{x}_i^\top$; $S=X^\top X/n$.

$Su_j=\lambda_ju_j$, $\lambda_1\ge\cdots\ge\lambda_d\ge0$. $S=S^\top\succeq0$; $U_m=[u_1,\dots,u_m]\in\mathbb{R}^{d\times m}$ có orthonormal columns, $1\le m\le d$: $U_m^\top U_m=I_m$.

Variance / direction $\|u\|=1$: $V(u)=\frac{1}{n}\sum_i(u^\top\tilde{x}_i)^2=u^\top Su$. Lagrangian $u^\top Su-\lambda(u^\top u-1)$ cho $Su=\lambda u$; maximize variance bằng top eigenvalues.

Scores / reconstruction

$z_i=U_m^\top\tilde{x}_i$, $Z=XU_m\in\mathbb{R}^{n\times m}$. $\hat{\tilde{x}}_i=U_mU_m^\top\tilde{x}_i$, $\hat{X}=ZU_m^\top$. Raw reconstruction $\hat{x}_i=\bar{x}+\hat{\tilde{x}}_i$; $\hat{X}\in\mathbb{R}^{n\times d}$ chứa centered reconstructions.

Variance / optimal reconstruction

$$E_m=\frac{1}{n}\|X-\hat{X}\|_F^2=\sum_{j>m}\lambda_j.$$

$$R(m)=\frac{\sum_{j\le m}\lambda_j}{\sum_j\lambda_j},\quad\text{tr}(S)>0.$$

E_m: mean squared Euclidean error; $R(m)$: retained variance ratio. Closest-point projection + Pythagoras:

$$\|\tilde{x}_i-\hat{\tilde{x}}_i\|^2=\sum_{j>m}(u_j^\top\tilde{x}_i)^2.$$

EX $S=\left[\begin{smallmatrix}2.5&2\\2&2.5\end{smallmatrix}\right]$: $\lambda=(4.5,.5)$, $u_1=(1,1)^\top/\sqrt{2}$. Giữ 1 PC: 90% variance; mean squared Euclidean error $.5$.

! Dùng train mean; sign tùy ý, repeated eigenvalues cho nonunique basis. Đổi sang $1/(n-1)$ scale eigenvalues, không đổi directions.

14 WHITENING / RECONSTRUCTION

Đặt $\Lambda_m=\text{diag}(\lambda_1,\dots,\lambda_m)$; $Z^\top Z/n=\Lambda_m$. Với $\lambda_m>0$: $w_i=\Lambda_m^{-1/2}z_i$, $W=Z\Lambda_m^{-1/2}$. $W^\top W/n=I_m$, $\hat{X}=W\Lambda_m^{1/2}U_m^\top$. Whitening = PCA scores / standard deviations.

Rank / invertibility Giữ $m=d$: $\hat{X}=X$.

$E_m = 0$ iff mọi discarded eigenvalue bằng 0; $m < \text{rank}(X) \Rightarrow E_m > 0$.

! Không chia cho zero eigenvalues. Unit covariance không suy ra independent/Gaussian. Sau full whitening mọi unit direction có variance bằng nhau.

15 FEATURE PCA / AUTOENCODER

Map $\phi : \mathbb{R}^d \to \mathbb{R}^M; \Phi_{raw} \in \mathbb{R}^{n\times M}$ có row i là $\phi(x_i)^\top$. Center *sau* mapping: $\bar\phi = \frac{1}{n}\sum_i \phi(x_i), \quad \Phi = \Phi_{raw} - \mathbf{1}_n\bar\phi^\top$. Center input chưa đủ với nonlinear ϕ. $S_\phi = \Phi^\top\Phi/n \in \mathbb{R}^{M\times M}$. $S_\phi U_m^\phi = U_m^\phi\Lambda_m^\phi$. Top orthonormal $U_m^\phi = [u_1^\phi, \dots, u_m^\phi] \in \mathbb{R}^{M\times m}$ (largest eigenvalues). $Z^\phi = \Phi U_m^\phi \in \mathbb{R}^{n\times m}$. Reconstruction $\hat\Phi = Z^\phi(U_m^\phi)^\top$; cộng $\bar\phi$ để về raw features.

! Good feature reconstruction ⇏ good input reconstruction; ϕ có thể noninvertible.

Autoencoder / MLP (sl. 58–59) Input d, latent bottleneck m, hidden q; elementwise σ. Encoder: $z_i = E_\theta(x_i) = A\sigma(W_e x_i + b)$. $W_e \in \mathbb{R}^{q\times d}, b \in \mathbb{R}^q, A \in \mathbb{R}^{m\times q}$. Decoder: $\hat x_i = D_\psi(z_i) = B\sigma(V_d z_i + c)$. $V_d \in \mathbb{R}^{q\times m}, c \in \mathbb{R}^q, B \in \mathbb{R}^{d\times q}$. Output $\in \mathbb{R}^d$; reconstruction loss:

$$\min_{\theta,\psi} \frac{1}{n}\sum_i \|x_i - \hat x_i\|^2.$$

Target $= x_i$, không cần y_i. Joint minibatch SGD cập nhật θ, ψ bằng backprop qua decoder rồi encoder.

16 K-MEANS / HARD ASSIGNMENT

Chọn K trước; $z_i \in \{1, \dots, K\}$: $J(z,\mu) = \sum_i \|x_i - \mu_{z_i}\|^2$. Lloyd: initialize centers → assign nearest center → update mean → repeat. $z_i \leftarrow \arg\min_k \|x_i - \mu_k\|^2$. $\mu_k \leftarrow \frac{1}{|C_k|}\sum_{i\in C_k} x_i$. Mỗi step không tăng J; local optimum phụ thuộc init. Empty cluster phải có rule (vd. reseed). Khởi tạo khác nhau có thể dẫn tới các local optima khác nhau.

EX 1D $x = (0, 2, 8, 10)$, centers $(0, 8)$: assignments $\{0, 2\}, \{8, 10\}$; means $(1, 9)$; $J = 4$.

Assumptions / geometry Squared Euclidean thích clusters gần spherical, scale tương tự. Scaling features đổi assignment. Hard boundary là Voronoi partition.

! Không tự chọn K; không bảo đảm global minimum. Monotone objective không suy ra clustering đúng về ý nghĩa.

17 GAUSSIAN / MIXTURE DENSITY

d-dimensional Gaussian ($\Sigma \succ 0$):

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{e^{-\frac{1}{2}(x-\mu)^\top\Sigma^{-1}(x-\mu)}}{(2\pi)^{d/2}|\Sigma|^{1/2}}.$$

Mahalanobis distance dùng Σ^{-1}; determinant chuẩn hóa density. Diagonal Σ cho independent coordinates *trong Gaussian component*.

Mixture model

$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$. $\pi_k \ge 0$, $\sum_k \pi_k = 1$. Latent label z: $P(z = k) = \pi_k$; $p(x \mid z = k) = \mathcal{N}_k(x)$. Log-likelihood $\ell(\theta) = \sum_i \log \sum_k \pi_k \mathcal{N}_k(x_i)$. Một Gaussian MLE: $\hat\mu = n^{-1}\sum_i x_i$, $\hat\Sigma = n^{-1}\sum_i (x_i - \hat\mu)(x_i - \hat\mu)^\top$.

! Density có thể > 1; posterior responsibility luôn trong $[0, 1]$. Mixture Gaussian không nhất thiết Gaussian.

Bayes rule / latent labels

$P(A \mid B) = P(B \mid A)P(A)/P(B)$. Posterior = likelihood × prior, rồi normalize qua mọi components. Không bỏ prior khi mixture weights khác nhau.

18 EM: E-STEP / M-STEP

E-step dùng *old* parameters, Bayes rule:

$$r_{ik} = P(z_i = k \mid x_i) = \frac{\pi_k \mathcal{N}_k(x_i)}{\sum_j \pi_j \mathcal{N}_j(x_i)}.$$

$\sum_k r_{ik} = 1$ với mỗi sample. Đặt $N_k = \sum_i r_{ik}$; M-step:

$$\pi_k^+ = N_k/n, \qquad \mu_k^+ = \frac{\sum_i r_{ik} x_i}{N_k},$$

$$\Sigma_k^+ = \frac{1}{N_k}\sum_i r_{ik}(x_i - \mu_k^+)(x_i - \mu_k^+)^\top.$$

Compute mọi responsibility trước, rồi update mọi parameter; covariance dùng *new* mean.

Algorithm loop Initialize $\pi_k, \mu_k, \Sigma_k \to$ compute normalized responsibilities → weighted parameter updates → evaluate log-likelihood → repeat đến tolerance / iteration budget.

! Không bảo đảm global optimum. Covariance phải valid; collapse quanh một point có thể làm likelihood tăng vô hạn. Tránh divide-by-zero khi component effective count quá nhỏ.

Hard vs soft K-means: one-hot assignment theo Euclidean distance. GMM: probability assignment theo prior, covariance shape và density. Equal isotropic covariance + equal priors cho nearest-mean posterior maximizer.

19 MDP / RETURNS / POLICY

MDP $(\mathcal{S}, \mathcal{A}, p, r, \gamma)$; $p(s', r \mid s, a)$ là joint next-state/reward distribution. Markov: next outcome phụ thuộc current state/action, không cần toàn history.

$G_t = \sum_{k\ge 0} \gamma^k R_{t+k+1}, \quad 0 \le \gamma < 1$.

Stochastic policy $\pi(a \mid s)$; deterministic $\mu : \mathcal{S} \to \mathcal{A}$. $V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$. $Q^\pi(s,a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$. $V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s,a)$.

COND Finite discounted results dưới đây dùng finite states/actions và bounded rewards. Episodic $\gamma = 1$ cần thêm assumptions; không áp dụng contraction một cách máy móc.

20 BELLMAN: EXPECTATION / MAX

Với $r(s,a) = \mathbb{E}[R_{t+1} \mid s, a]$: Policy evaluation:

$$Q^\pi(s,a) = r(s,a) + \gamma \mathbb{E}[V^\pi(S') \mid s, a],$$

$$V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s,a).$$

$P^\pi_{ss'} = \sum_a \pi(a \mid s) P(s' \mid s, a)$, $r^\pi_s = \sum_a \pi(a \mid s) r(s,a)$: $V^\pi = r^\pi + \gamma P^\pi V^\pi, \quad V^\pi = (I - \gamma P^\pi)^{-1} r^\pi$.

Optimality:

$$Q^*(s,a) = r(s,a) + \gamma \mathbb{E}[V^*(S') \mid s, a],$$

$$V^*(s) = \max_a Q^*(s,a).$$

Thay $V^*(s') = \max_{a'} Q^*(s', a')$ cho action-value optimality equation. Greedy policy $\mu^*(s) \in \arg\max_a Q^*(s,a)$.

! Fixed π: average theo π, không max. Q^π lấy action a trước rồi theo π; optimal V, Q unique, optimal policy có thể không unique.

21 VALUE ITERATION / ERROR

Khởi tạo V_0 (thường 0). Mỗi sweep:

$$q_k(s,a) = r(s,a) + \gamma \sum_{s'} P(s' \mid s, a) V_k(s'),$$

$$V_{k+1}(s) = \max_a q_k(s,a).$$

Synchronous: mọi state dùng *old* V_k. Viết action candidates trước khi lấy max; terminal continuation = 0 nếu terminal không có future rewards.

Contraction / stopping

$\|T^*V - T^*U\|_\infty \le \gamma \|V - U\|_\infty$; $\|V_k - V^*\|_\infty \le \gamma^k \|V_0 - V^*\|_\infty$. Nếu $\Delta_k = \|V_{k+1} - V_k\|_\infty$:

$$\|V_{k+1} - V^*\|_\infty \le \frac{\gamma}{1-\gamma}\Delta_k.$$

EX One-state self-loop, reward $r(a)$: $V^* = \max_a r(a)/(1-\gamma)$. Với $r = 2, \gamma = .5$: $V^* = 4$; $V_0 = 0 \to 2 \to 3 \to 3.5 \to \cdots$.

! Convergence asymptotic không có nghĩa exact optimum trong finite sweeps. Greedy action cần $r + \gamma PV$, không chỉ largest immediate reward.

22 POLICY ITERATION / IMPROVE

1. Chọn deterministic μ. 2. Evaluate $(I - \gamma P^\mu)V^\mu = r^\mu$. 3. $\mu^+(s) \in \arg\max_a [r(s,a) + \gamma \sum_{s'} P(s' \mid s, a) V^\mu(s')]$. 4. Repeat đến policy stable.

Policy improvement: nếu $Q^\pi(s, \pi'(s)) \ge V^\pi(s)$ mọi s, thì $V^{\pi'} \ge V^\pi$.

COND Finite MDP + exact evaluation: finite termination với consistent tie handling (giữ old action nếu đang maximizer). Value iteration khác: backup values, không solve full policy mỗi sweep.

23 MONTE CARLO / TD(0)

Model-based biết p, r; model-free dùng sampled transitions. MC estimates $V^\pi(s)$ bằng average observed returns G_t; cần completed return, không bootstrap.

TD target / error

$\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t)$. $V(s_t) \leftarrow V(s_t) + \alpha\delta_t$. TD dùng one-step sample + current value estimate; update trước episode end. Nếu true terminal, bootstrap term 0.

! $V(s') > V(s)$ không đủ để update tăng; phải xét reward *và* discount. TD bootstrap có bias từ estimate, MC thường variance cao hơn.

24 Q-LEARNING / EXPLORATION

Learn Q^* trực tiếp từ transition sample (s, a, r, s'): $y = r + \gamma \max_{a'} Q(s', a')$. $Q(s,a) \leftarrow Q(s,a) + \alpha[y - Q(s,a)]$. Target theo Bellman optimality, khác TD evaluation của fixed policy. Current transition chỉ update visited state-action entry.

Behavior vs target ε-greedy: probability ε chọn random action, otherwise chọn $\arg\max_a Q(s,a)$. Exploration tạo samples; target vẫn dùng greedy max ở next state.

! Không thay $\max_{a'} Q(s', a')$ bằng $\max_{a'} Q(s, a')$. True terminal không bootstrap. Function approximation không tự kế thừa convergence của tabular updates.

25 DQN / REPLAY / TARGET NET

Approximate $Q(s, a; \theta)$ bằng neural net. Store (s, a, r, s', d) trong replay buffer; sample random minibatch. $d = 1$ khi true terminal.

$y = r + \gamma(1 - d) \max_{a'} Q(s', a'; \theta^-)$.

$$L(\theta) = \frac{1}{B}\sum_{j=1}^B [y_j - Q(s_j, a_j; \theta)]^2.$$

Giữ target y fixed khi differentiate; optimizer update θ; định kỳ copy $\theta^- \leftarrow \theta$.

Why two mechanisms? Replay giảm sequential correlation và tái sử dụng data; target net làm target thay đổi chậm hơn. Behavior policy tạo data có thể khác greedy target policy.

! Replay không bắt buộc từ current policy. Terminal target $= r$. Neural approximation + bootstrap + off-policy có thể bất ổn; target/replay không chứng minh global convergence.

26 POWER METHOD / PAGERANK

PCA covariance $S \succeq 0$ (mục 13)

$$v_{t+1} = \frac{Sv_t}{\|Sv_t\|_2}.$$

Với $\lambda_1 > \lambda_2, \alpha_1 = u_1^\top v_0 \ne 0$: normalized iterates hội tụ về $\pm u_1$.

$\rho = \frac{\lambda_2}{\lambda_1} < 1$, direction error $O(\rho^t)$. Dense covariance, slide 39:

Full EVD : $O(d^3)$,

m PCs (iter.) : $O(md^2)$/iteration.

PageRank Với importance truyền theo outgoing links, chọn column-stochastic matrix A: $A_{ij} = 1/d_j^{out}$ nếu $j \to i$. Stationary importance thỏa $Ar = r$. $r_{t+1} = Ar_t$. Eigenvalue 1; normalize giúp ổn định số và giữ probability interpretation.

Teleportation Repair dangling columns bằng probability vector v. Với $0 \le \alpha < 1$: $r_{t+1} = \alpha A r_t + (1 - \alpha)v$. $\mathbf{1}^\top v = 1, v > 0$ cho positive Google matrix và unique stationary distribution.

! Row-stochastic A + column vector: cần transpose. Undamped iteration có thể không converge dù có eigenvalue 1.